캡스톤 프로젝트 강화학습 설계서

현실감 강화(Managed Realism) 반영판

문서 상태

버전: v2.0

목적: 이전 단순화 버전에서 관리 가능한 현실감 강화 방향으로 설계를 재정렬한 개정본

이번 개정의 핵심

기존의 discrete 8 방향 + 즉발 규칙에서 hybrid action + 엔진 보정 구조로 전환한다.

연속 이동은 정책이 직접 속도를 완전히 제어하는 방식이 아니라, 엔진 컨트롤러가 acceleration 과 turn-rate 를 적용하는 방식으로 단순화한다.

train 60 초 / eval 90 초 / demo 120 초 프로필을 분리하고, staged run 으로 현실감 요소를 순차 도입한다.

1. 문서 개요와 설계 원칙

1.1 목적

본 문서는 2D 2 대 2 전투 AI 의 학습 문제 정의, observation/action space, reward 구조, trainer 전략, staged run 계획을 정의한다. 이번 개정의 핵심은 현실감 강화 요소를 추가하면서도 학습 가능한 spec 를 유지하는 데 있다.

1.2 핵심 설계 원칙

- 보이는 현실감은 continuous movement + turn-rate cap + weapon timing + fast projectile 에서 확보한다.
- 정책 action 차원은 hybrid action 수준에서 멈추고, free aim angle 은 이번 학기 제외한다.
- reward 는 학습에만 영향을 주며, evaluation 에서는 같은 이벤트를 metric 으로만 해석한다.
- 현실감 요소는 staged run 으로 순차 도입한다.

2. v2 변경 요약

영역	이전안	v2 설계
전투 규칙	8 방향 이동 + 즉발	continuous 2 축 이동 + fast projectile + windup/recovery
action space	전부 discrete multi-branch	continuous 2 + discrete target + discrete fire hybrid
조준	사실상 즉시 정렬	target-select 유지 + turn-rate cap 엔진 처리
시간 프로필	짧은 단일 라운드	train 60 초 / eval 90 초 / demo 120 초
단계화	reward 중심 단계화	제어 요소와 reward 요소를 모두 단계화

3. 학습 문제 정의와 알고리즘 선택

3.1 문제 유형

문제는 2 대 2 부분 협동·부분 경쟁(top-down combat) 환경에서의 멀티에이전트 강화학습이다. 각 팀 내부에서는 공동 승리 목표와 팀 안전 규칙이 존재하고, 상대 팀과는 경쟁 관계를 가진다.

3.2 기본 알고리즘 방향

- 우선안: 팀 reward 를 다루기 쉬운 cooperative-aware trainer + self-play 조합
- fallback: PPO + self-play + individual reward 비중 확대

- 마감 리스크가 커질 경우 임시 fallback 으로 fixed baseline 상대 학습 허용

3.3 Behavior / Team / Group 규칙

- 한 scene 안의 동일 역할 agent 는 같은 behavior spec 를 공유한다.
- 같은 팀 agent 는 동일 team id 를 사용하고, cooperative reward 처리를 위해 같은 group 단위로 관리한다.
- train/eval/demo 에서 behavior spec 자체는 동일해야 한다.

4. 전투 환경과 에피소드 설계

4.1 모드별 시간 프로필

프로필	기본 시간	용도
train	60 초	학습 속도와 현실감의 균형
eval	90 초	더 안정적인 비교 지표 확보
demo	120 초	발표용 장면 확보
showcase(optional)	180 초	시간이 충분할 때만 사용

4.2 tick 설계

- physics tick 은 더 짧은 고정 간격으로 유지하고, decision 은 그보다 느린 주기로 요청한다.
- 정책이 낸 action 은 다음 decision 시점까지 컨트롤러가 유지·보간한다.
- 이 구조 덕분에 policy 가 매 프레임 free aim 을 낼 필요 없이도 부드러운 움직임이 가능하다.

4.3 1 차 전투 규칙

- 연속 이동, cover blocking, target-select 기반 조준, fast projectile, windup/recovery, friendly fire on
- reload, multi-weapon, explosive damage 는 제외
- projectile 은 finite speed 를 가지되 너무 느리게 두지 않는다

5. Observation 설계

5.1 센서 조합 선택

1 차 설계는 visual observation 을 사용하지 않고 vector observation + ray sensor 를 사용한다. 현실감 강화는 입력을 이미지화하는 대신, 물리·상태 규칙을 더 사람답게 만드는 방식으로 달성한다.

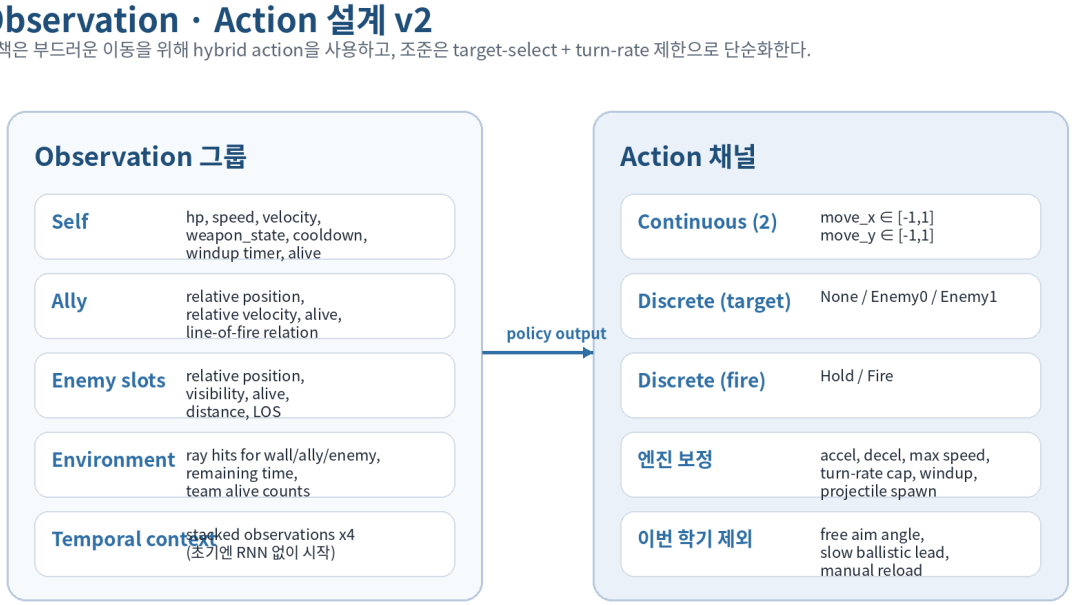

그림 1. observation 과 action 설계 v2

5.2 vector observation 구성

그룹	예시 필드	비고
Self	hp, normalized speed, velocity x/y, alive flag, current weapon_state, cooldown, windup timer	정확한 차원 수는 구현 시 고정
Ally	relative position x/y, relative velocity x/y, alive flag, line-of-fire relation	아군과의 간섭 해석에 사용
Enemy0 / Enemy1	relative position x/y, visible flag, alive flag, distance, LOS flag	phase 1 에서는 짧은 memory 보다 현재 상태를 우선
Global	remaining time, ally alive count, enemy alive count, mode profile index(optional)	episode 종료 맥락 제공

5.3 ray sensor 권장 설정

- wall, ally, enemy 를 구분하는 2D ray perception 을 사용한다.
- 목적은 시각 인식 대체가 아니라 cover 근접 정보와 즉시 충돌 위험을 제공하는 것이다.
- ray 수와 범위는 staged run 에서 늘릴 수 있지만, 초기에는 디버깅 가능한 수준으로 제한한다.

5.4 temporal context

- 초기에는 stacked observations x4 를 사용해 짧은 peek / hide 문맥을 제공한다.
- RNN 또는 LSTM 은 phase 2 이후 선택 사항으로 남긴다.

5.5 전처리 원칙

- 절대좌표보다 상대좌표를 우선 사용한다.
- 속도, 각도 차, 체력, 시간은 고정 범위로 정규화한다.
- map seed, 미래 판정값, 상대 reward 등 누설 정보는 관측에 넣지 않는다.

6. Action Space 설계

6.1 hybrid action 선택

이번 개정의 action space 는 continuous 2 축 이동과 discrete target / fire 채널을 함께 사용하는 hybrid action 이다. 이동은 부드럽게 만들고, 조준은 free aim 이 아닌 target-select + turn-rate cap 으로 단순화해 action 차원을 억제한다.

채널	형태	값 / 의미
move_x	continuous	[-1, 1], 좌우 이동 의도
move_y	continuous	[-1, 1], 상하 이동 의도
target_select	discrete	0=None, 1=Enemy0, 2=Enemy1
fire_intent	discrete	0=Hold, 1=Fire

6.2 행동 적용 규칙

- move_x, move_y 는 즉시 위치를 바꾸지 않고 MovementController 가 acceleration / deceleration / max speed 를 적용한다.
- target_select 는 desired aim angle 을 결정하고, AimController 가 현재 각도에서 그 방향으로 천천히 회전한다.
- fire_intent 는 WeaponController 에 전달되며, 현재 상태가 Ready 일 때만 windup 진입을 허용한다.

6.3 invalid action 처리

- 사망한 적을 target_select 한 경우 None 또는 가장 가까운 살아있는 적으로 보정하지 않고, 기본적으로 None 처리한다.
- recovery 중 fire_intent 는 무시한다.
- LOS 가 끊긴 상태에서 windup 을 유지할지 취소할지는 config rule 로 명시한다. 초기안은 취소 우선이다.

7. Reward 설계

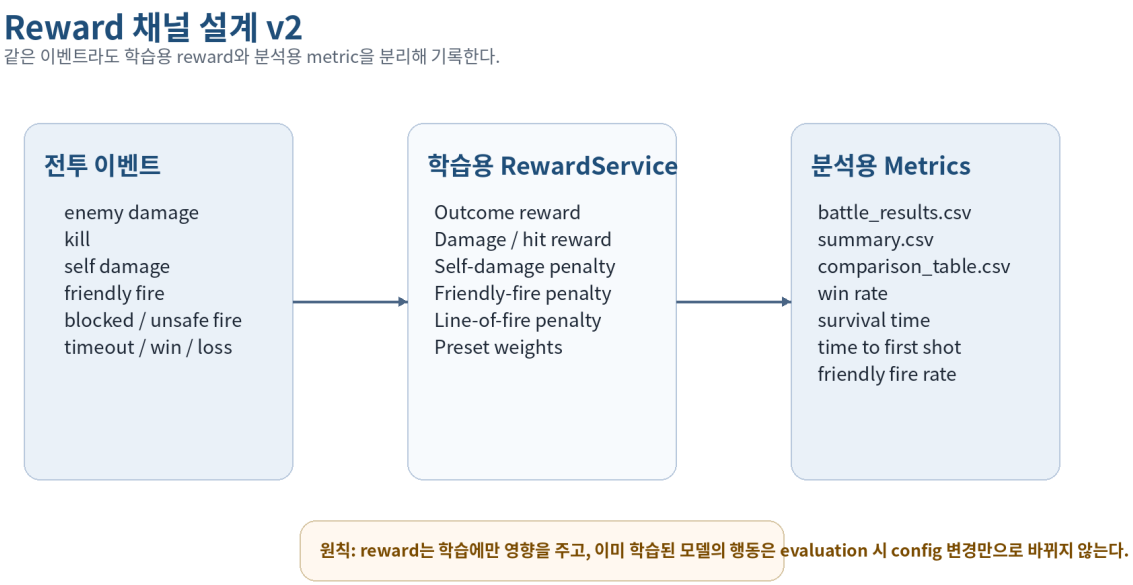

그림 2. reward channel 과 analysis metric channel 분리

7.1 reward 채널 구조

RewardService 는 training reward channel 과 analysis metric channel 을 분리한다. evaluation 과 demo 에서는 동일 이벤트를 수집하더라도 AddReward 를 호출하지 않고 CSV 및 보고용 메트릭으로만 저장한다.

7.2 고정 outcome reward

- win reward / loss penalty / draw 또는 timeout 처리 규칙을 고정 outcome reward 로 둔다.
- outcome reward 는 모든 프리셋에서 동일하게 유지한다.

7.3 사용자 편집 대상 reward term

reward term	의도	기본 방향
enemy damage / hit	교전 참여를 유도	양수
kill	결정적 성과 강화	양수
survival	무리한 돌진 완화	작은 양수 또는 time-based bonus
self-damage	무분별한 교전 억제	음수
friendly fire	팀 안전 확보	강한 음수
line-of-fire / blocked fire	아군이 사선에 있을 때 난사 억제	작은 음수

7.4 preset 예시 방향

preset	상대적으로 크게 두는 항목	기대 행동

aggressive	enemy damage, kill	빠른 교전 진입, 높은 사격 빈도
balanced	damage, survival, safety 를 균형 유지	무리하지 않되 교전 회피도 지나치지 않음
survival	survival, self-damage penalty, safety	교전 간격을 조절하고 오래 버팀

7.5 단계별 reward 활성화

- R0: outcome + damage + self-damage 만 사용
- R1: survival term 추가
- R2: friendly fire penalty 추가
- R3: line-of-fire 또는 blocked fire penalty 추가

7.6 reward anti-pattern

- 한 step 에서 지나치게 큰 reward 를 주지 않는다.
- 현실감 요소를 reward 로만 억지 구현하려 하지 않는다. 움직임·사격 템포는 엔진 규칙으로 반영한다.
- 이미 학습된 모델의 행동을 config 변경만으로 해석하려 하지 않는다.

8. Trainer 설정과 staged run 전략

8.1 기본 trainer 방향

- 우선안은 self-play 와 cooperative reward 를 함께 다루기 쉬운 trainer 를 사용한다.
- 불안정 시 PPO + self-play 또는 fixed baseline 상대 학습으로 후퇴할 수 있다.

8.2 self-play 운영 규칙

- 평가와 달리 학습에서는 대칭 self-play 또는 baseline 혼합을 사용한다.
- checkpoint pool 과 상대 샘플링 규칙은 run manifest 에 기록한다.

8.3 staged run

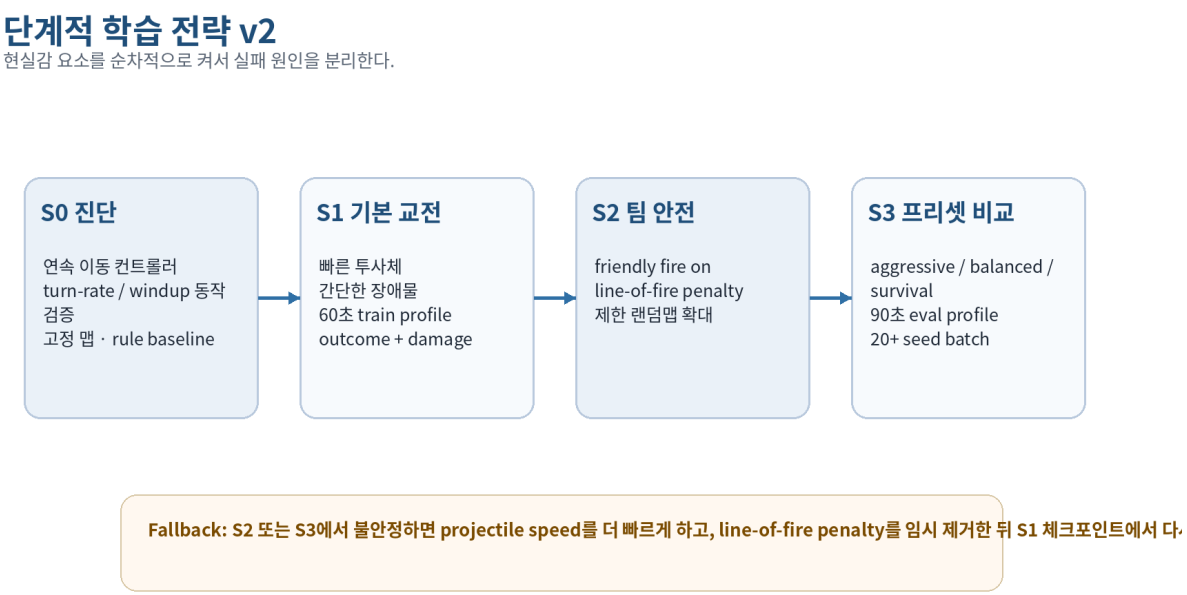

그림 3. 단계적 학습 전략 v2

- S0: movement / aim / weapon controller 진단, 고정 맵
- S1: fast projectile + 간단한 장애물 + 기본 reward
- S2: team safety reward 와 제한 랜덤맵 확대
- S3: preset 간 비교와 eval profile 고정

8.4 checkpoint selection 규칙

- 최종 checkpoint 만 사용하지 않고, fixed seed 평가에서 가장 안정적인 model_id 를 선택한다.
- 과적합이나 특정 seed 편향을 막기 위해 train 중간 checkpoint 도 후보에 포함한다.

8.5 fallback 순서

- projectile speed 를 높여 더 단순한 hit timing 으로 되돌린다.
- line-of-fire penalty 를 임시 제거하고 friendly fire penalty 만 남긴다.
- 맵 복잡도를 낮추고 S1 checkpoint 에서 다시 시작한다.
- 필요 시 trainer 를 PPO fallback 으로 전환한다.

9. 평가와 해석을 위한 RL 지표

9.1 training-time stats

- episode reward, policy loss, entropy, win rate proxy, timeout rate
- weapon windup 취소율, projectile hit rate 같은 진단 지표는 별도 metric channel 로 볼 수 있다.

9.2 evaluation batch 시 기본 시나리오

- aggressive vs survival
- balanced vs baseline
- same preset mirror match
- friendly fire penalty on/off 단일 변수 비교

9.3 핵심 비교 지표

지표	의미
win rate	기본 성능
survival time	버티는 성향
damage dealt	공격 효율
friendly fire rate	팀 안전성
time to first shot	초기 반응 및 템포
mean shot interval	windup/recovery 기반 발사 리듬
path length	연속 이동이 만든 기동량

9.4 seed 프로토콜

- 평가 seed list 는 사전에 고정한다.
- 학습 seed 전략과 평가 seed list 는 분리한다.
- 비교 표에는 seed count 와 profile name 을 함께 기록한다.

10. 자주 발생하는 실패 모드와 대응

실패 모드	가능한 원인	대응
지나친 난사	windup 이 너무 짧거나 damage reward 가 과도함	windup 상향, blocked fire penalty 추가
제자리 떨림	가속·감속 파라미터 불안정	movement smoothing 조정, stop epsilon 도입
쏘지 않음	projectile hit feedback 희박, safety penalty 과도	projectile speed 상향, penalty scale 재조정
항상 같은 방향만 봄	target selection 실패, visibility 정보 부족	LOS / visible flag 점검, target_select 분포 확인

학습 불안정	현실감 요소를 한 번에 과도하게 활성화	S1 단계로 rollback 후 재시작

11. 바로 구현에 사용할 수 있는 순서

- 1) continuous movement 와 turn-rate cap 을 엔진 계층에 먼저 구현한다.
- 2) weapon state machine 과 fast projectile 를 붙이고 diagnostic scene 으로 검수한다.
- 3) observation / action spec 를 고정하고 baseline 과 연결한다.
- 4) reward stage R0 부터 학습을 시작하고 점진적으로 R3 까지 확장한다.
- 5) eval 90 초 profile 과 comparison export 를 붙여 발표용 결과를 만든다.

부록 A. 예시 설정 구조

```
{
  "mode_profile": {
    "name": "train",
    "max_duration_sec": 60
  },
  "movement": {
    "max_speed": 4.0,
    "acceleration": 12.0,
    "deceleration": 16.0
  },
  "aim": {
    "turn_rate_deg_per_sec": 360
  },
  "weapon": {
    "windup_sec": 0.18,
    "recovery_sec": 0.35,
    "projectile_speed": 20.0
  },
  "reward": {
    "damage": 0.2,
    "kill": 1.0,
    "survival": 0.02,
    "self_damage": -0.2,
    "friendly_fire": -0.6
  }
}
```

부록 B. 이번 학기 제외 항목 재확인

- free aim angle continuous action
- slow projectile lead aiming 을 기본 성공 조건으로 요구하는 것
- 기본 training profile 180 초 고정
- reload, multi-weapon, stance system